TP4 - Naive Bayes, RNN, LSTM, Transformers

Réponse complète au TP4 : Classification de Texte et Analyse de Sentiments

Étudiant : Boudaoud Sid Ahmed

1. Objectifs

Ce TP vise à comparer quatre approches pour l'analyse de sentiments sur des tweets : Naive Bayes (baseline), RNN simple, LSTM/BiLSTM, et un Transfo...

2. Préparation des données et nettoyage

2.1 Chargement et exploration

2.2 Nettoyage spécifique aux tweets

Ce choix est fondamental : retirer `not` détruit le sens de constructions comme `"not good"`, `"not bad at all"`, ou `"don't like"`, ce qui est par...

3. Partie 1 : Naive Bayes (Baseline)

3.1 Vectorisation

3.2 Résultats Naive Bayes

Matrice de confusion (TF-IDF) :

3.3 Mots/bigrammes les plus discriminants

Ces bigrammes montrent que Naive Bayes bénéficie fortement de paires de mots fréquentes dans les tweets, mais reste limité par l'absence de modélis...

4. Partie 2 : RNN Simple et LSTM

4.1 Préparation pour les modèles séquentiels

4.2 Résultats

4.3 Observations

Les courbes d'apprentissage sont disponibles dans `figures/` (`rnn_*.png`, `lstm_*.png`, `bilstm_*.png`).

5. Partie 3 : Transformer (DistilBERT)

5.1 Approche

5.2 Résultats

Matrice de confusion :

5.3 Test qualitatif sur phrases complexes

| Phrase | Prédiction DistilBERT | Analyse |

Ces résultats montrent la capacité des Transformers à modéliser le contexte global et à résoudre des cas ambigus où l'ordre et le contexte l'emport...

6. Partie 4 : Évaluation comparative

6.1 Tableau récapitulatif

*(Configuration actuelle : échantillon 40k, CPU, epochs réduites pour faisabilité ; avec plus de données/GPU/epochs, le Transformer dépasse général...

6.2 Comparaison visuelle

7. Questions d'analyse et de justification

Question 1 : Hypothèse de Naive Bayes - "naïve" et limites face aux négations

Limites avec les inversions de polarité :

C'est pourquoi le prétraitement doit **impérativement conserver** `not/no/never` plutôt que de les retirer comme stopwords classiques.

Question 2 : RNN Simple vs LSTM - Vanishing gradient et portes

Solution apportée par LSTM et rôle des portes

- **Forget gate** $f_t = \sigma(W_f [h_{t-1}, x_t] + b_f)$: décide quelles informations de C_{t-1} doivent être **oubliées** (filtrage du passé ...

Cette architecture permet un **flux de gradient plus stable** le long de l'état de cellule (connexion additive $C_{t-1}\to C_t$) atténuant considér...

Question 3 : Pourquoi les Transformers surpassent-ils les modèles récurrents sur Sentiment140 ?

1. **Self-Attention (parallélisation et accès direct)**

2. **Contexte bidirectionnel natif**

3. **Tokenisation sous-lexicale (WordPiece)**

4. **Pré-entraînement sur de grands corpus**

5. **Meilleure modélisation des phénomènes pragmatiques**

Sur notre configuration CPU/échantillon réduit, BiLSTM et Transformer sont très proches ; avec un entraînement complet sur GPU et plus d'époques, l...

Question 4 : Analyse des erreurs et impact de LSTM puis Transformer sur négations/ironie

D'après les matrices de confusion et le comportement typique :

Impact par modèle

| Phénomène | Naive Bayes | RNN Simple | LSTM | BiLSTM | Transformer |

Exemples concrets issus de nos tests qualitatifs (Transformer)

Conclusion sur l'erreur : Le passage vers LSTM/BiLSTM aide significativement pour les dépendances longues et la négation simple/modérée. Le pas...

Question 5 : Compromis Performance / Coût de calcul - Quand privilégier Naive Bayes ou LSTM plutôt qu'un Transformer ?

| Critère | Naive Bayes (TF-IDF) | LSTM/BiLSTM | Transformer (DistilBERT) |

Recommandations selon le contexte réel :

- **Privilégier Naive Bayes si :**

- **Privilégier LSTM/BiLSTM si :**

- **Privilégier Transformer si :**

Observation sur nos résultats : Dans ce setup contraint (CPU, échantillon 40k, epochs réduites), **BiLSTM (F1=0.775)** et **Naive Bayes (F1=0.7...

8. Conclusion

- **Naive Bayes** reste une baseline solide, ultra-rapide et explicable. Sa principale faiblesse est l'ignorance de l'ordre et du scope de la négat...

Annexes